

مسئله ۱.

(الف)

first-iteration: $\mu_1 = 0 \xrightarrow{\text{فوته ۱}} \{1\} \Rightarrow \mu_1 = \frac{1}{1} = 1$

$\mu_2 = 3 \xrightarrow{\text{فوته ۲}} \{2, 1, 9\} \Rightarrow \mu_2 = \frac{2+1+9}{3} = 4, \bar{3}$

Second-iteration: $\mu_1 = 1 \xrightarrow{\text{فوته ۱}} \{1, 2\} \Rightarrow \mu_1 = \frac{1+2}{2} = 1,5$

$\mu_2 = 4, \bar{3} \xrightarrow{\text{فوته ۲}} \{1, 9\} \Rightarrow \mu_2 = \frac{1+9}{2} = 1, \bar{5}$

third-iteration: $\mu_1 = 1,5 \xrightarrow{\text{فوته ۱}} \{1, 2\}$
 $\mu_2 = 1, \bar{5} \xrightarrow{\text{فوته ۲}} \{1, 9\}$
 کلاً شد است.

مقدار تابع هزینه:

$$J = \sum_{n=1}^N \sum_{k=1}^K w_{nk} \|x_n - \mu_k\|^2 = (1-1,5)^2 + (2-1,5)^2 + (1-1,5)^2 + (9-1,5)^2$$

$$= 4, \bar{5} \left(\frac{1}{2}\right)^2 = 1$$

(ب)

مرحله ۱: هر فوته را به نزدیک ترین مفا-فوته تخصیص می کنیم. معیار نزدیک بودن فوته i به مفا-فوته j ، $\|x_i - \mu_j\|$ است. پس برای هر فوته i ، تقصی می کنیم که بهر به کدام j نزدیک تر است و به همان مفا-فوته j آن را تخصیص می کنیم.

مرحله ۲: در این مرحله مراکز مفا-فوته ها به روز رسانی می شود. برای این کار هر j ، باور با میانگین بهر های که به آن تخصیص یافته اند می شود. یعنی مرکز هر مفا-فوته، باور میانگین مراکز فوته های است که به آن مفا-فوته تخصیص یافته اند. رابطه ی ریاضی این به روز رسانی به شکل معادل است:

$$\mu_m = \frac{\sum_{i=1}^N y_{im} \mu_i}{\sum_{i=1}^N y_{im}}$$

مرحله ۳: در واقع همان مرحله E در حالت K-means عادی است. در این مرحله داده را به نزدیکترین خوشه تخصیص می‌دهیم. ملاک نزدیک بودن هم برای داده n، خوشه K به این شکل است: $\|x_n - \mu_K\|$

مرحله ۴: در واقع همان مرحله M در حالت K-means عادی است. مرکز هر خوشه را برابر با میانگین داده‌های آن خوشه تخصیص یافته است (که در اینجا همان مرکز خوشه از رابطه زیر بدست می‌آید):

$$\mu_K = \frac{\sum_{n=1}^N I_{nK} x_n}{\sum_{n=1}^N I_{nK}}$$

مسئله ۲. الف:

$$P(F) = P(F), P(A) = P(A), P(S) = \sum_F \sum_A P(S|F,A) P(F)P(A)$$

$$P(H) = \sum_S P(H|S) P(S), P(N) = \sum_S P(N|S) P(S)$$

$$P(F,A,S,H,N) = P(N|F,A,S,H) P(H|A,S,F) P(S|F,A) P(F|A) P(A)$$

رابطه بالا از chain-rule بدست می‌آید. از طرفی طبق مدل زیر داریم:

$$\left. \begin{aligned} P(N|F,A,S,H) &= P(N|S) \\ P(H|A,S,F) &= P(H|S) \\ P(F|A) &= P(F) \end{aligned} \right\} P(F,A,S,H,N) = P(N|S) P(H|S) P(S|F,A) P(F) P(A)$$

ب:

$$P(A=1|F,S,H,N) = \frac{P(A=1, F, S, H, N)}{P(F, S, H, N)} = \frac{P(A=1, F, S, H, N)}{P(A=0, F, S, H, N) + P(A=1, F, S, H, N)}$$

با استفاده از رابطه بدست آمده در قسمت الف (توسط chain-rule و مدل زیر) داریم:

$$P(A, F, S, H, N) = P(A) P(F) P(S|F,A) P(N|S) P(H|S)$$

$$P(A=1 | F, S, H, N) = \frac{P(A=1) P(F) P(S | F, A=1) P(N | S) P(H | S)}{P(F) P(N | S) P(H | S) [P(A=0) P(S | F, A=0) + P(A=1) P(S | F, A=1)]}$$

$$= \frac{P(A=1) P(S | F, A=1)}{P(A=0) P(S | F, A=0) + P(A=1) P(S | F, A=1)}$$

(ب) طبق تعریف مدل های Markov blanket، باید فرزندان A، والدین A، و والدین فرزندان A را انتخاب کنیم. A والد ندارد. فرزند A می شود S. و والد فرزند A می شود F. پس جواب می شود S و F. این جواب منطقی است. چرا که در قسمت (ب) بیان نموده ایم که برای پیدا کردن $P(A | F, S, H, N)$ تنها به متغیرهای F و S نیاز داریم. (علامه بر A). پس جواب همان S و F است.

(ت) در همان بخشی (ب) به جواب ساده شده مورد نظر رسیدیم:

$$P(A=1 | F, S, H, N) = \frac{P(A=1) P(S | F, A=1)}{\sum_A P(A) P(S | F, A)}$$

(ث) متغیر unobserved همان A است. پس پارامترهایی که به A ربط دارند، نیازمند محاسبه گام ۴ هستند. از بخشی های قبلی دانستیم که:

$$P(F, A, S, H, N) = P(F) P(A) P(S | F, A) P(H | S) P(N | S)$$

حالا، که مشاهده می شود در ۲ عبارت متغیر A ظاهر شده است:

$$P(A), P(S | F, A)$$

بنابر این پارامترهای $P(A=1)$ ، $P(S=1 | F=1, A=0)$ ، $P(S=1 | F=1, A=1)$ ،

$P(S=1 | F=0, A=0)$ و $P(S=1 | F=0, A=1)$ نیازمند محاسبه گام ۴ هستند.

(ج)

$$P(A=1) = \arg \max_{P(A=1)} \sum_{i=1}^{\infty} \sum_z Q(z) \log P(A)$$

محاسبه تخمین $P(A=1)$

$$= \log P(A=1) + \log P(A=1) + 0 + 1 \log P(A=1) + 1 \log P(A=1)$$

$$+ 0 + 0 + \log P(A=0) + 1 \log P(A=0) + 1 \log P(A=0)$$

$$= 2.2 \log P(A=1) + 1.8 \log P(A=0) = 2.2 \log(P(A=1)) + 1.8 \log(1 - P(A=1)) = E$$

$$\frac{dE}{dP(A=1)} = 0 \Rightarrow \frac{2.2}{P(A=1)} + \frac{-1.8}{1 - P(A=1)} = 0 \Rightarrow P(A=1) = 0.44$$

محاسبه تخمین $P(S=1 | F=0, A=1)$

$$P(S=1 | F=0, A=1) = \arg \max \sum_z Q(z) \log P(S=1 | F=0, A=1)$$

$$= \log P(S=1 | F=0, A=1) + \log P(S=0 | F=0, A=1)$$

$$+ 1 \log P(S=0 | F=0, A=1) + 1 \log P(S=1 | F=0, A=1)$$

$$= 1.4 \log P(S=1 | F=0, A=1) + 1.8 \log(1 - P(S=1 | F=0, A=1)) = E$$

$$\frac{dE}{dP(S=1 | F=0, A=1)} = \frac{1.4}{P(S=1 | F=0, A=1)} + \frac{-1.8}{1 - P(S=1 | F=0, A=1)} = 0 \Rightarrow P(S=1 | F=0, A=1) = \frac{7}{14}$$

برای بیشینه کردن آن پایین داریم:

$$\max_z \sum_z Q(z) \log \frac{P(x, z | \theta)}{Q(z)} = \max \left\{ \sum_z Q(z) \log \frac{P(z | x, \theta)}{Q(z)} + \sum_z Q(z) \log P(x | \theta) \right\}$$

$$\sum_z Q(z) \log P(x | \theta) \rightarrow \text{const}$$

می توانیم متغیر معکوس بجای $Q(z)$ بکار ببریم. کافی است یکس باز بکار ببریم. \Rightarrow صواب کنیم

$$\Rightarrow \min \sum_z Q(z) \log \frac{Q(z)}{P(z | x, \theta)} = \min \sum_k q_k \log \frac{q_k}{z_k}$$

با استفاده از فرایب لگاریتم داریم:

$$\sum_k q_k \log \frac{q_k}{z_k} + \beta (\sum_k q_k - 1) - \sum_k \alpha_k q_k = L(\theta, q, \beta, \alpha)$$

$$\frac{\partial L}{\partial q_k} = 0 \Rightarrow \log \frac{q_k}{z_k} + 1 + \beta - \alpha_k = 0 \Rightarrow q_k = z_k e^{\alpha_k - 1 - \beta}$$

$$\Rightarrow L(\theta, q, \beta, \alpha) = \sum_k z_k e^{\alpha_k - 1 - \beta} - \beta$$

اگر $q_k = 0$ پس q_k مساوی صفر، خواصی دارد: $q_k = z_k$

در صورتی که $z_k \neq 0$ ، طبق کارایز بنی می شود که $\alpha_k \neq 0$ (زیرا $q_k \neq 0$).

پس اگر $\alpha_k = 0$ داریم:

$$q_k = z_k e^{-1 - \beta} \Rightarrow e^{-1 - \beta} = 1 \Rightarrow -1 - \beta = 0 \Rightarrow \boxed{\beta = -1}$$

که نتیجه می شود $\boxed{q_k = z_k}$.

ب.

جیبی رابطی انکار کے نام :

$$E[\log P(Z, x | \theta)] = \sum_{i=1}^N \sum_{j=1}^K \gamma_{ji} \underbrace{\left(\log \frac{e^{-\lambda_j} \lambda_j^{m_i}}{m_i!} + \log \pi_j \right)}_{P(m_i; \lambda_j)} = J$$

$$\frac{\partial J}{\partial \lambda_k} = 0 \Rightarrow \frac{\partial}{\partial \lambda_k} \sum_{i=1}^N \gamma_{ki} \left(\log \frac{e^{-\lambda_k} \lambda_k^{m_i}}{m_i!} + \log \pi_k \right) = 0$$

$$\frac{\partial \log \frac{e^{-\lambda_k} \lambda_k^{m_i}}{m_i!}}{\partial \lambda_k} = \frac{\partial}{\partial \lambda_k} \log e^{-\lambda_k} + \frac{\partial}{\partial \lambda_k} \log \frac{\lambda_k^{m_i}}{m_i!}$$

$$= -1 + \frac{m_i}{\lambda_k} \Rightarrow \sum_{i=1}^N \gamma_{ki} \left(-1 + \frac{m_i}{\lambda_k} \right) = 0 \Rightarrow \lambda_k = \frac{\sum_{i=1}^N \gamma_{ki} m_i}{\sum_{i=1}^N \gamma_{ki}}$$

$$\frac{\partial E[\log P(Z, x | \theta)] + \lambda \left(1 - \sum_{i=1}^K \pi_i \right)}{\partial \pi_k} = 0$$

$$\Rightarrow \frac{1}{\pi_k} \sum \gamma_{ki} - \lambda = 0 \Rightarrow \left\{ \begin{array}{l} \pi_k = \frac{\sum \gamma_{ki}}{\lambda} \\ \sum_{i=1}^K \pi_k = 1 \Rightarrow N = \lambda \end{array} \right\} \pi_k = \frac{\sum_{i=1}^N \gamma_{ki}}{N}$$

خب این سؤال علاوه بر اینها جواب داده شده است.

رضی که برای نامرطبی ۱-۱ اگر درستی داشته ایم. یعنی V_i و V_{i-1} جواب برای مرطبی ۱-۱ هستند.

$$\max_{V_i} \frac{1}{N} \sum_{n=1}^N (V_i^T x^{(n)} - V_i^T \bar{x})^2 = V_i^T S V_i, \quad V_i^T V_j = \begin{cases} 1 & \text{if } i=j \\ 0 & \text{o.w.} \end{cases}$$

$$\mathcal{L}(V_i, \lambda_i, \alpha) = V_i^T S V_i - \sum_{j=1}^{i-1} \alpha_j V_i^T V_j + \lambda_i (1 - V_i^T V_i)$$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial V_i} = S V_i - \sum_{j=1}^{i-1} \alpha_j V_j - \lambda_i V_i = 0$$

$$\Rightarrow \forall k \in \{1, i-1\} : V_k^T [S V_i - \sum_{j=1}^{i-1} \alpha_j V_j - \lambda_i V_i] = 0$$

$$\Rightarrow \left. \begin{aligned} & V_k^T S V_i = \alpha_k V_k^T V_k = \alpha_k \\ & \underbrace{V_k^T S}_{\text{بردار دژه}} = \lambda_k V_k^T \end{aligned} \right\} \quad V_k^T S V_i = \lambda_k \underbrace{V_k^T V_i}_0 = 0 = \alpha_k$$

$$\Rightarrow \forall k \in \{1, i-1\} \quad \alpha_k = 0$$

$$\frac{\partial \mathcal{L}}{\partial V_i} = S V_i - \sum_{j=1}^{i-1} \alpha_j V_j - \lambda_i V_i = 0, \quad \alpha_j = 0$$

$$\Rightarrow S V_i = \lambda_i V_i \Rightarrow V_i \text{ بردار ویژه } \lambda_i$$

$$\max_k V_i^T S V_i = \max_k V_i^T \lambda_i V_i = \max_k \lambda_i$$

بنابراین نام محدود شده در الگوریتم PCA، بردار ویژه مناسب با این بزرگترین مقدار دژه است.

(ب)

$$K(x, x') = x^T x' \quad , \quad S = \frac{1}{N} x \cdot x^T$$

↳ ماتریس کواریانس

به ازای بردار ویژه K (مثلاً b) داریم:

$$\left. \begin{array}{l} Kb = \lambda b \\ K = x x^T \end{array} \right\} x^T x b = \lambda b \xrightarrow[\text{ضرب در } x]{\text{از چپ در } x} x x^T x b = \lambda x b \rightarrow (1)$$

$$S = \frac{1}{N} x x^T \Rightarrow x x^T = N S \quad \left. \begin{array}{l} N S x b = \lambda x b \\ (1) \end{array} \right\} S x b = \lambda x b$$

بنابراین $x b$ بردار ویژه S است. پس داریم:

$$S \cdot (x b) = \lambda (x b)$$

از طرفی با توجه به ماتریس کرنل داریم:

$$V_i = \sum b_j \phi(x_j) = x b$$

$$\Rightarrow S \cdot (x b) = \lambda (x b) \Rightarrow \boxed{S V_i = \lambda V_i}$$

بنابراین با استفاده از کرنل خطی، مسئله PCA حل شد (به ازای یک جواب دلخواه).
بنابراین این روش با بکلیگر معادل هستند.

نکته مهم: در روش حل فرض شد که میانگین داده‌ها صفر است بنابراین عبارت $x - \bar{x}$ به x تبدیل شد.
این فرض از کلیت مسئله کم می‌کند چرا که می‌توان داده‌ها را با کیفیت داده‌ها میانگین صفر شود و راه حل در آن.

(ب) جنب ابتدا ماتریس داده ها را تجزیه SVD می کنیم.

$$X = U \Sigma V^T$$

$$\Rightarrow X^T X = V \Sigma^T U^T U \Sigma V^T, \quad U^T U = I$$

$$\Rightarrow X^T X = V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

از تجزیه SVD می دانیم که درایه های قطر اصلی ماتریس Σ در واقع مقادیر ویژه ماتریس X هستند. پس ماتریس Σ که $\Sigma^T \Sigma$ است، روی قطر اصلی اش توان دوم مقادیر ویژه X را دارد.

از روش PCA، مطلوب مقادیر ویژه ماتریس $\frac{1}{n} X^T X$ می باشد. (و در ادامه بردار ویژه متناظر آن ها) پس اگر درایه های قطر اصلی Σ را s_i بنامیم، مقادیر ویژه ماتریس $\frac{1}{n} X^T X$ برابر با $\frac{s_i^2}{n}$ می شود. پس از روش تجزیه SVD دما دریافت می کنیم، می توانیم مقادیر ویژه دیگری داشته باشیم. بردار ویژه حاضر ستون های V در تجزیه SVD است.

(ت)

ماتریس داده ها را $X_{n \times d}$ در نظر بگیریم.

روش SVD از ارد زمانی $O(nd \min(n, d))$ است.

روش کولمبایی از مرتبه $O(nd^2)$ است.

پس اگر ابعاد داده ما یعنی d بیشتر از n باشد، روش SVD برابر $O(n^2 d)$ می شود که چون $n < d$ ، از $O(nd^2)$ بهتر است.

پس در این حالت استفاده از روش SVD بهتر است.